

UNIVERSIDAD TECNOLÓGICA NACIONAL FACULTAD REGIONAL SANTA FE

NutrIA: Diseño e implementación de una plataforma con IA para la generación segura y asistida de planes alimentarios y viandas personalizadas por nutricionistas licenciados

Cátedra: Proyecto Final

Carrera: Ingeniería en Sistemas de Información

Integrante: Herrmann, Cristian Andrés – cherrmann@frsf.utn.edu.ar

Director: Esp. Pacchiotti, Mauro José – mpacchiotti@frsf.utn.edu.ar

Codirectora: Dra. Ballejos, Luciana Cristina – lballejos@frsf.utn.edu.ar

Año 2026

Índice

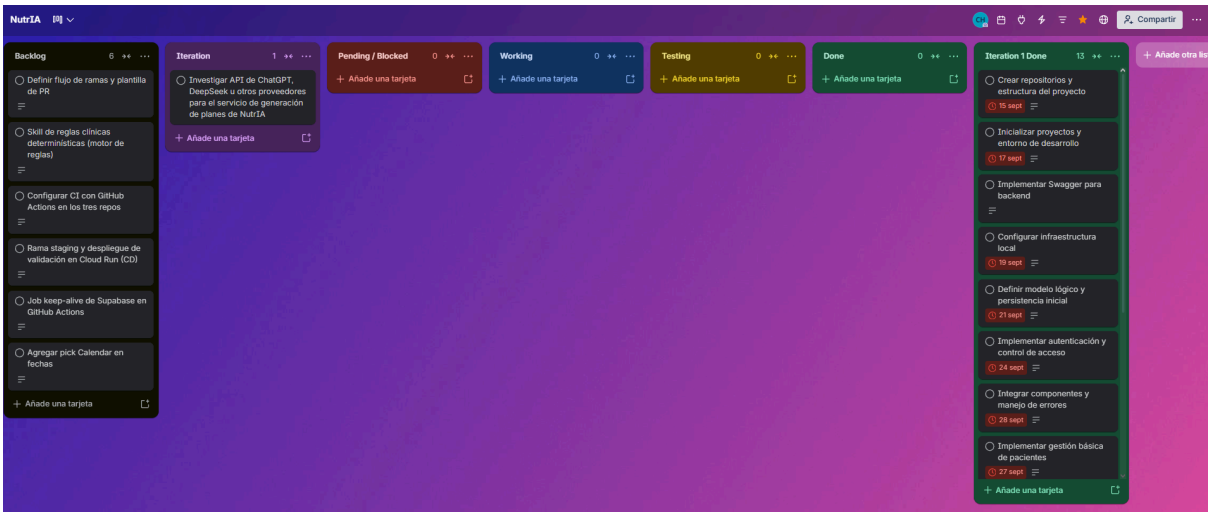
Avances del incremento 1.....3
Arquitectura detallada..... 3
Vista de ejecución local..... 3
Backend..... 4
Contrato de la API..... 5
Seguridad y aislamiento de datos..... 6
Frontend..... 6
Servicio de IA..... 6
Modelo de datos..... 8
Tecnologías seleccionadas..... 9
Decisiones registradas..... 10
Criterios de selección del proveedor de IA..... 12
Aclaraciones respecto del Plan de Proyecto..... 15
Metas cuantitativas de los objetivos específicos..... 15
Estructura temporal de los planes: diarios y semanales..... 16
Viandas personalizadas..... 16
Conclusiones y próximos pasos.....17

Avances del incremento 1

El Incremento 1 tenía como alcance la estructura base del sistema, la configuración inicial del proyecto, la autenticación de nutricionistas, el modelo inicial de datos y las funcionalidades básicas de gestión de pacientes. Para hacer una gestión a alto nivel de las tareas se utilizó Trello para realizar un tablero de tareas, con una tarjeta por tarea que define alcance y criterio de aceptación o cierre.

En la figura 1 se muestra ya el incremento 1 completado en Trello. A cada tarjeta se la identifica con un título y dentro tiene una descripción de la tarea a realizar, en algunos casos con fecha de vencimiento, sobre todo para organizar mejor qué debía hacerse primero ya que resultaba bloqueante para el resto o para un bloque de tareas. También se muestran ciertas tareas que se dejan en backlog para próximos incrementos.

Figura 1. Tablero de tareas



A medida que se avanza con el desarrollo, se van agregando tareas que en principio no estaban pensadas ya que dependen de decisiones que se adoptaron en el momento de planificar los incrementos.

Arquitectura detallada

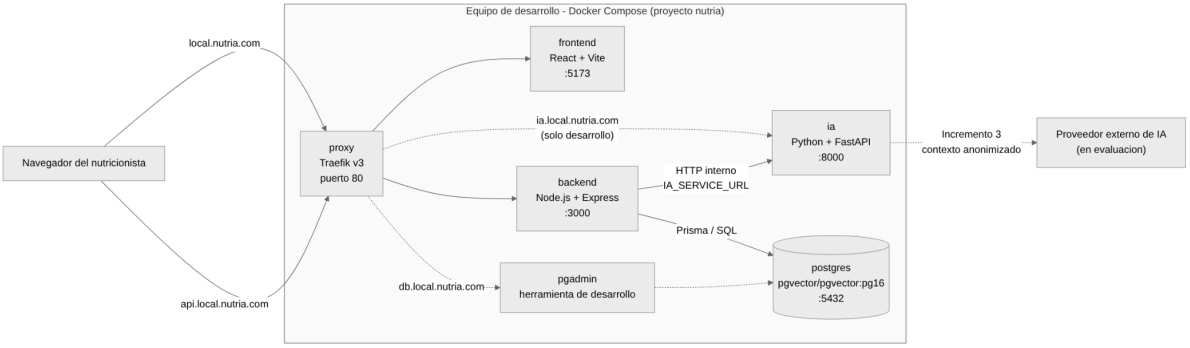
La arquitectura conserva la estructura definida en el Informe de Avances 1 (IA1) : un frontend web, un backend modular que concentra la lógica de negocio y el motor determinístico de reglas clínicas, un servicio de inteligencia artificial desacoplado y una base de datos PostgreSQL. Esta sección detalla cada componente con el nivel alcanzado en el Incremento 1 y precisa el diseño previsto para los componentes que se implementarán en los incrementos siguientes.

Vista de ejecución local

La figura 2 muestra la vista de ejecución local en el entorno de desarrollo. El sistema completo se ejecuta con Docker Compose. Un proxy inverso (Traefik) enruta las solicitudes por nombre de

dominio local, de modo que cada componente se accede por un host propio y no por un puerto distinto, lo que se asemeja a la forma de acceso de un entorno desplegado.

Figura 2. Vista de ejecución local del sistema con Docker Compose.



La siguiente tabla muestra los servicios definidos en Docker Compose, detallando la tecnología y que función cumple, además de como se expone en el entorno local de desarrollo.

Tabla 1. Servicios definidos en Docker Compose

Servicio	Imagen / tecnología	Función	Exposición
proxy	Traefik v3.1	Proxy inverso por nombre de dominio.	Puerto 80 del equipo
frontend	Node 22 + Vite (React 19)	Interfaz web del nutricionista.	`local.nutria.com`
backend	Node 22 + Express	API REST, autenticación, lógica de negocio y documentación de la API.	`api.local.nutria.com`, `swagger.local.nutria.com`
ia	Python 3.12 + FastAPI	Servicio de generación asistida (esqueleto en este incremento).	`ia.local.nutria.com`
postgres	pgvector/pgvector:pg16	Persistencia. La extensión vectorial está disponible pero no activada.	Puerto 5433 del equipo
pgadmin	pgAdmin 4	Inspección de la base durante el desarrollo.	`db.local.nutria.com`

El browser nunca se va a comunicar con el servicio de IA; toda solicitud pasa por el backend, que lo alcanza por la red interna de Docker. El host `ia.local.nutria.com` existe únicamente para consultar su documentación durante el desarrollo.

Backend

El backend está organizado por capas con responsabilidades separadas. Cada endpoint declara en la ruta sus middlewares de autenticación y validación; los controllers solo leen datos ya validados y

delegan en los servicios; los servicios concentran la lógica de negocio; y los repositorios son el único punto de acceso a la base de datos. En la tabla 2 se muestra la organización que se describe.

Tabla 2. Responsabilidad de cada capa del backend.

Carpeta	Responsabilidad
`routes/`	Define los endpoints, encadena middlewares y documenta la operación con bloques OpenAPI.
`middlewares/`	Autenticación (`requireAuth`), validación de entrada (`validate`), ruta inexistente y manejador central de errores.
`schemas/`	Esquemas Zod de entrada. El mismo esquema se usa para alta y edición de pacientes.
`controllers/`	Traducen la solicitud HTTP en una llamada al servicio y devuelven la respuesta serializada.
`services/`	Lógica de negocio: login, gestión de pacientes, estado del servicio de IA.
`repositories/`	Consultas con Prisma. Toda consulta de pacientes exige el identificador del nutricionista.
`serializers/`	Forma de la respuesta: omite el identificador del nutricionista y agrega la edad calculada.
`clients/`	Único punto de llamada al servicio de IA, con tiempo máximo de espera y error controlado.
`domain/reglas/` (previsto)	Motor determinístico de reglas clínicas, a partir del Incremento 3. Se implementa como funciones puras sobre el plan, el paciente y el catálogo, que devuelven hallazgos bloqueantes o de advertencia.

Los módulos funcionales del backend crecerán por incremento siguiendo esta misma estructura: datos clínicos, consultas y catálogos en el Incremento 2; generación asistida y reglas clínicas en el Incremento 3; aprobación, versionado, trazabilidad y exportación en el Incremento 4; y seguimiento en el Incremento 5.

Contrato de la API

El contrato se documenta con OpenAPI, generado a partir de los comentarios de las rutas, y se consulta en una interfaz Swagger que reúne en un mismo lugar la definición de backend y la del servicio de IA.

Todos los errores de la API responden de la forma `{ error: { code, message, details? } }`

El campo `code` es estable (por ejemplo, `VALIDATION_ERROR`, `UNAUTHORIZED`, `NOT_FOUND`, `CONFLICT`, `INTERNAL_ERROR`, `IA_UNAVAILABLE`) y los errores de validación incluyen el detalle por campo en details.fields, que el frontend muestra junto al campo correspondiente del formulario. Un error no reconocido responde con un mensaje fijo, sin exponer el mensaje interno ni la traza, que solo se registra en el log del servidor.

Seguridad y aislamiento de datos

El RNF-05 establece que cada nutricionista accede exclusivamente a sus propios pacientes. El mecanismo implementado tiene tres niveles:

- El identificador del nutricionista se obtiene únicamente del token verificado. Un identificador enviado por el cliente en el cuerpo de la solicitud es rechazado.
- Toda consulta del servicio de pacientes filtra por ese identificador. Un paciente de otro nutricionista responde 404, de forma indistinguible de un paciente inexistente, para no revelar su existencia.
- El repositorio interrumpe con un error cualquier consulta que llegue sin identificador de nutricionista. Esta salvaguarda cubre errores de programación, como una ruta a la que se olvide aplicar el middleware de autenticación.

Las contraseñas se almacenan con hash bcrypt. Ante credenciales inválidas, el login responde siempre con el mismo mensaje y realiza la comparación incluso cuando el correo no existe, para no revelar qué dato falló ni permitir distinguir ambos casos por tiempo de respuesta. Las credenciales y secretos se configuran por variables de entorno y ningún archivo `.env` se versiona (RNF-06). Los datos de prueba son ficticios (RNF-08).

Frontend

El frontend es una aplicación de página única construida con React y Vite. Se organiza en páginas (`pages/`), componentes reutilizables (`components/`), un contexto de autenticación (`context/`) y una capa de acceso a la API (`api/`). Las rutas internas están protegidas: sin sesión válida se redirige al login, y al volver a ingresar el usuario retorna a la pantalla en la que estaba.

Todas las llamadas al backend pasan por un único cliente HTTP, que devuelve los datos o un error tipado con estado, código, mensaje y detalle por campo. Los fallos de red, los tiempos de espera agotados y las respuestas sin el formato de la API se convierten en mensajes comprensibles para el usuario. Una respuesta 401 cierra la sesión y muestra un aviso de sesión expirada.

Los estilos se implementan con Tailwind CSS. Los colores, tamaños de texto y sombras del prototipo de Figma se definen una sola vez como tokens del tema, y las pantallas los referencian por nombre. En este incremento se implementaron las pantallas de login, inicio, listado de pacientes, ficha (pestaña Resumen), alta y edición de paciente, y página de recurso no encontrado. Las secciones del prototipo que corresponden a incrementos posteriores se ocultan o se muestran como próximas.

En el siguiente enlace se encuentra el diseño en Figma de las interfaces implementadas: https://www.figma.com/design/AuzQCvhIihxqK765bupn9o/Nutria?node-id=0-1&t=juNUlvnEn0FbrXwk-1

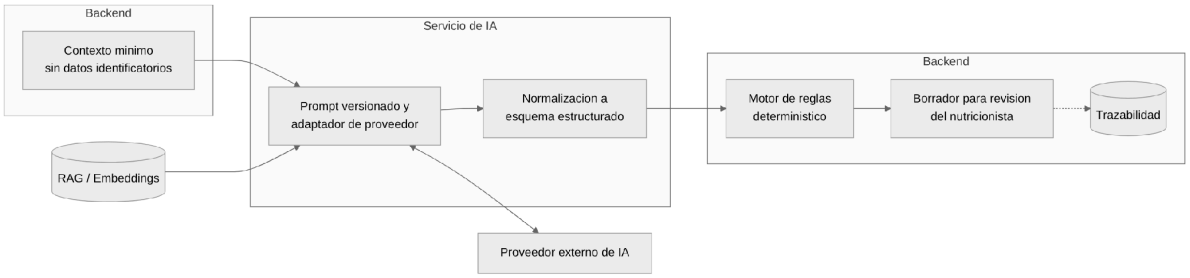
Servicio de IA

En el Incremento 1 el servicio de IA es un esqueleto en FastAPI con un endpoint de estado y documentación OpenAPI automática. Su integración con el backend ya está resuelta: el backend lo invoca a través de un cliente único con tiempo máximo de espera, y si el servicio no responde

devuelve un error controlado (503) en lugar de dejar la solicitud bloqueada. Este comportamiento es la base del RNF-02 para la generación asistida.

El diseño previsto para el Incremento 3 se muestra en la Figura 3. Mantiene las decisiones del IA1: el servicio de IA no accede a la base de datos operativa, recibe un contexto mínimo sin datos identificatorios (RNF-07), construye la solicitud al proveedor externo, no aplica reglas clínicas y normaliza la respuesta a un esquema estructurado. La validación determinística, la persistencia del borrador y la trazabilidad quedan en el backend.

Figura 3. Diseño simplificado: responsabilidades del backend y del servicio de IA.



- **Contexto mínimo construido en el backend**. El backend arma el contexto a partir de las condiciones del paciente (RF-07), su contexto de cocina, comidas fuera del hogar y horarios (RF-08 a RF-10), y el subconjunto del catálogo de alimentos permitido, excluyendo los alimentos rechazados (RF-37). Nombre, contacto, fecha de nacimiento y demás datos identificatorios no salen del backend.
- **Validación del contrato de entrada en el servicio de IA**. El servicio define su entrada con Pydantic y rechaza cualquier campo no previsto. Esto concreta la responsabilidad de anonimización que el IA1 asignaba al servicio de IA como una segunda barrera: la minimización se realiza en origen, en el backend, y el servicio verifica que la solicitud no contenga datos fuera del contrato antes de enviarla al proveedor.
- **Plantillas de prompt versionada**s. Cada generación registra la versión de plantilla utilizada, lo que permite comparar resultados entre versiones.
- **Adaptador de proveedor**. El servicio define una interfaz común de generación y una implementación por proveedor. El cambio de proveedor queda acotado al adaptador y a la configuración (riesgo 5).
- **Salida estructurada y resolución contra el catálogo**. La propuesta se devuelve organizada por tipo de comida, opciones e ítems. El backend vincula cada ítem con un alimento del catálogo antes de ejecutar el motor de reglas, de modo que la validación opere sobre datos estructurados y no sobre texto libre (RF-39, RF-43). El tratamiento de los ítems que no se reconozcan en el catálogo es un punto de diseño abierto para el Incremento 3.
- **Error controlado**. Un tiempo de espera agotado, una falla del proveedor o una respuesta que no respeta el esquema se informan como error recuperable, con posibilidad de reintento y sin pérdida de lo cargado (RNF-02).
- **Revisión profesional y trazabilidad**. La propuesta validada se guarda como borrador con sus hallazgos, y el flujo continúa como se presentó en el IA1: revisión, edición, revalidación ante cada cambio (RF-46) y aprobación exclusiva del nutricionista. El backend registra el contexto enviado, la versión de plantilla, la respuesta, el resultado de la validación y las modificaciones

relevantes del profesional (RF-41, RNF-11). El mismo recorrido aplica a la generación de recetas (RF-39).

El tiempo máximo de espera configurado actualmente en el backend corresponde a la verificación de estado. La generación requerirá un tiempo máximo propio, que se fijará a partir de las mediciones del proveedor seleccionado y de la meta de 15 segundos tratada en la sección de aclaraciones.

Recuperación de información (RAG). Conforme al Plan de Proyecto, el servicio de IA incorpora recuperación aumentada sobre un corpus de bibliografía nutricional general, cuyo contenido se agrega al prompt para fundamentar las propuestas y reducir la información inventada o no verificable (riesgo 18). Se adoptan tres condiciones de diseño: el corpus no contiene datos de pacientes; está separado del motor de reglas, de modo que ninguna restricción clínica dependa de información recuperada automáticamente (riesgo 15); y se almacena con la extensión vectorial de PostgreSQL en una base separada de la operativa, a la que accede solo el servicio de IA, de forma que se mantiene la decisión del IA1 de que este servicio no acceda a los datos de pacientes. La biblioteca de implementación (LangChain o LlamaIndex, según el Plan) y la composición del corpus se definirán al implementar el componente.

Modelo de datos

El modelo conceptual de IA1 se implementa de forma incremental mediante migraciones de Prisma. El archivo schema.prisma constituye el modelo lógico vigente. En el Incremento 1 se implementaron las entidades NUTRICIONISTA y PACIENTE con los campos de RF-02, RF-03, RF-15 y RF-17. En la tabla 3 se muestra cómo se van a incorporar las demás entidades, de acuerdo a los incrementos definidos en IA 1 y en el plan de proyecto.

La obligatoriedad de los datos del adulto responsable para pacientes menores (RF-17) se valida en la aplicación y no en la base de datos, porque depende de la fecha de nacimiento, que es opcional y puede completarse en una consulta posterior (RF-15, RNF-03).

Tabla 3. Incorporación prevista de entidades del modelo conceptual por incremento.

Incremento	Entidades del IA1
1 (implementado)	NUTRICIONISTA, PACIENTE (datos personales, objetivo, responsable, registro incompleto).
2	Datos clínicos y contextuales del PACIENTE, PACIENTE_CONDICION, CONSULTA, mediciones, laboratorio, hábitos pautados, GRUPO_ALIMENTO, ALIMENTO, RECETA y entidades asociadas, recomendaciones.
3	PLAN, PLAN_COMIDA, OPCION, OPCION_ITEM, REGLA_CLINICA, HALLAZGO, GENERACION_IA.
4	Estados de aprobación, versionado y vínculo entre planes; fechas de aprobación y exportación.

Tecnologías seleccionadas

Durante las secciones anteriores se fue detallando algunas de las tecnologías implementadas. La Tabla 4 actualiza la tabla de tecnologías previstas del IA1 con las tecnologías y versiones efectivamente utilizadas. Se indica para cada una si la selección es definitiva (implementada y sin cambio previsto), preliminar (decidida pero no implementada) o en evaluación.

Tabla 4. Tecnologías seleccionadas.

Componente	**Tecnología (versión)**	**Estado**	**Uso y justificación**
Frontend	React 19, Vite 8, React Router 7	Definitiva	Previsto en el Plan e IA1. Vite reemplaza a Next.js porque la aplicación no requiere renderizado del lado del servidor: es de uso interno del nutricionista, autenticado y sin indexación pública.
Estilos	Tailwind CSS 4	Definitiva	Framework principal para dar estilos en lugar de utilizar CSS manual
Backend	Node.js 22, Express 5	Definitiva	Previsto en el Plan e IA1.
Validación de entrada	Zod 4	Definitiva	Esquemas declarativos por endpoint, con mensajes por campo reutilizados por el frontend.
Acceso a datos	Prisma 6	Definitiva	Esquema declarativo como modelo lógico y migraciones versionadas y reproducibles.
Autenticación	jsonwebtoken 9, bcryptjs 3	Definitiva	Token firmado con vencimiento de 2 horas; contraseñas con hash.
Base de datos	PostgreSQL 16 (imagen pgvector)	Definitiva	Previsto en el Plan. La imagen incluye la extensión vectorial que utilizará el RAG.
Servicio de IA	Python 3.12, FastAPI, Uvicorn, Pydantic 2	Definitiva	Previsto en el Plan e IA1. Pydantic define los contratos de entrada y salida.
Proveedor de IA	API externa	En evaluación	Ver decisión DA-12.
RAG	Extensión vectorial de PostgreSQL; LangChain o LlamaIndex (Plan)	Preliminar	Recuperación sobre bibliografía nutricional general, en una base separada de la operativa. Ver DA-13.
Documentación de API	swagger-jsdoc, swagger-ui-express; OpenAPI de FastAPI	Definitiva	Previsto en el Plan (Swagger en ambos servicios).
Pruebas	Vitest 5	Definitiva	Misma herramienta en backend y frontend.
Calidad de código	oxlint (frontend)	Definitiva	Análisis estático del frontend.

Componente	Tecnología (versión)	Estado	Uso y justificación
Contenedores	Docker, Docker Compose	Definitiva	Previsto en el Plan (RNF-13).
Proxy local	Traefik 3.1	Definitiva	Ver decisión DA-08.
Control de versiones	Git, GitHub	Definitiva	Tres repositorios, uno por componente.
Despliegue	A definir	En evaluación	Ver Decisión DA-14
Gestión y diseño	Trello, Figma	Definitiva	Seguimiento de tareas y prototipo de interfaces.

Decisiones registradas

Las decisiones se registran con su motivo y sus consecuencias, conforme al registro de decisiones previsto en la sección 5.3 del Plan. En la tabla 5 se muestran las decisiones del IA1 que se ratifican y las adoptadas durante el Incremento 1 y las que quedan en evaluación para los incrementos siguientes.

Tabla 5. Registro de decisiones

ID	Decisión	Alternativas consideradas	Motivo y consecuencias
DA-01	Backend modular con un único servicio de IA desacoplado; motor de reglas clínicas en el backend (IA1, ratificada).	Motor de reglas dentro del servicio de IA; arquitectura de microservicios.	La validación clínica no depende del modelo generativo ni del proveedor (riesgos 1, 2, 4 y 18). Un único servicio adicional evita la complejidad de microservicios para un proyecto individual.
DA-02	Prisma para acceso a datos y migraciones.	Sequelize, Knex, SQL sin ORM.	El esquema declarativo sirve como modelo lógico documentable y las migraciones permiten reconstruir la base desde cero (riesgo 16).
DA-03	Imagen de PostgreSQL con extensión vectorial desde el inicio, sin activarla.	PostgreSQL estándar y cambio posterior.	Evita cambiar la imagen de base de datos al incorporar el RAG (DA-13), sin costo en el presente.
DA-04	Autenticación con JWT de 2 horas y contraseñas con bcrypt; el token se conserva en el navegador.	Sesiones en servidor; cookies httpOnly.	Solución simple y sin estado en el servidor. Al conservar el token en el navegador, la protección contra inyección de scripts es una condición de seguridad a mantener; se reevaluará antes del despliegue en producción.
DA-05	Aislamiento por nutricionista en tres niveles: token, servicio y repositorio. Un recurso ajeno responde 404.	Filtro solo en controladores.	Cumple RNF-05 aun ante errores de programación (riesgos 3 y 9). Cubierto por pruebas unitarias.

ID	Decisión	Alternativas consideradas	Motivo y consecuencias
DA-06	Validación de entrada con Zod y formato de error uniforme en toda la API.	Validación manual por endpoint.	Contrato estable entre backend y frontend (riesgo 11); los errores no exponen información interna.
DA-07	Alta de nutricionistas por seed en esta etapa.	Registro público; panel de administración.	No existe requerimiento de autorregistro. El panel queda como mejora futura fuera del catálogo vigente.
DA-08	Proxy inverso Traefik con dominios locales.	Un puerto por servicio.	Acceso por dominio similar al de un entorno desplegado y sin conflictos de puertos. Requiere configurar el archivo hosts del equipo.
DA-09	Documentación OpenAPI unificada del backend y del servicio de IA, montada solo fuera de producción.	Documentación separada; documentación expuesta en producción.	Facilita las pruebas manuales sin ampliar la superficie expuesta en producción.
DA-10	Tailwind CSS como framework de estilos.	CSS Modules; librerías de componentes (MUI, Chakra).	Mayor fidelidad al prototipo propio con menor esfuerzo.
DA-11	Pruebas unitarias en el Incremento 1; pruebas de integración y de extremo a extremo selectivas en incrementos posteriores	Cobertura completa desde el inicio.	Prioriza los casos de mayor riesgo (autenticación, aislamiento, validaciones) dentro del tiempo disponible. Las reglas clínicas tendrán pruebas obligatorias.
DA-12	Proveedor de IA en evaluación, detrás de un adaptador con interfaz común.	Fijar un proveedor antes de implementar.	Se están comparando modelos de baja latencia de distintos proveedores. La decisión se tomará antes del Incremento 3 con los criterios que se detallan en la sección “Criterios de selección del proveedor de IA”, y un cambio posterior queda acotado al adaptador (riesgos 5 y 19).
DA-13	RAG sobre bibliografía nutricional general en el servicio de IA, con el corpus en una base separada de la operativa.	Generación solo con el prompt; corpus en la base operativa.	Fundamenta las propuestas en bibliografía y reduce la información no verificable (riesgo 18). El corpus no contiene datos de pacientes y no interviene en la validación clínica, que sigue a cargo del motor de reglas (riesgo 15).
DA-14	Estrategia y plataforma de despliegue en evaluación.	Infraestructura propia; Oracle Cloud Infrastructure (OCI); GCP; alternativas similares de despliegue administrado.	Se realizó una evaluación preliminar de distintas alternativas de despliegue, considerando costo, complejidad de configuración y mantenimiento, disponibilidad, soporte para Docker y adecuación al alcance académico del proyecto. Se priorizarán opciones de bajo costo y administración sencilla. La plataforma definitiva se seleccionará antes del despliegue del prototipo funcional.

Criterios de selección del proveedor de IA

La selección del proveedor y del modelo de IA se realizará considerando criterios técnicos, económicos y de protección de datos. En esta etapa se busca reducir el conjunto de alternativas disponibles y establecer una base objetiva para su posterior evaluación sobre casos representativos de NutrIA.

- Latencia: Se priorizarán modelos con tiempos de respuesta compatibles con el objetivo establecido. Para la evaluación preliminar se consideran el tiempo hasta el primer token (TTFT) y la velocidad de generación (tokens/s). Posteriormente se medirá el tiempo total de respuesta utilizando casos reales de prueba de NutrIA.
- Salida estructurada: El modelo debe permitir respuestas ajustadas a un esquema estructurado, preferentemente mediante JSON Schema o mecanismos equivalentes. Esto facilita la validación determinística de la respuesta antes de incorporar al dominio de la aplicación.
- Calidad y consistencia: Se evaluará la capacidad del modelo para seguir instrucciones, mantener coherencia y producir resultados consistentes ante casos equivalentes. La evaluación específica se realizará posteriormente utilizando casos representativos del dominio y varias ejecuciones por caso.
- Política de datos: Se analizarán las condiciones relacionadas con retención de información, utilización de datos para entrenamiento, residencia y jurisdicción del procesamiento. Este criterio resulta especialmente relevante por el tipo de información que podría ser procesada por el sistema y se vincula con el RNF-07 y los riesgos identificados.
- Costo y disponibilidad: Se priorizarán alternativas cuyo costo por generación sea compatible con el carácter académico y de bajo costo del proyecto. También se considerará la disponibilidad sostenida de la API, estabilidad del proveedor y posibilidad de utilizar versiones posteriores sin cambios significativos en la arquitectura.

Se realizó una comparación inicial de modelos de distintos proveedores considerando costo de API, capacidad general y velocidad de generación. Esta comparación, que se muestra en la tabla 6, tiene carácter preliminar: los benchmarks generales permiten descartar alternativas poco convenientes, pero no determinan por sí solos cuál será el modelo más adecuado para NutrIA.

Tabla 6. Evaluación de modelos

Modelo	**Costo entrada / salida[1]**	**TTFT aprox.[2]**	**Velocidad aprox.[2]**	**Evaluación preliminar**
GPT-6 Luna	**0,10 / 0,50**	~2,4 s	~121 tok/s	**Prioridad alta.** Presenta la relación costo/capacidad más atractiva entre los modelos analizados. El nivel de razonamiento deberá ajustarse para cumplir el objetivo de latencia.

Modelo	Costo entrada / salida[1]	TTFT aprox.[2]	Velocidad aprox.[2]	Evaluación preliminar
DeepSeek V4.1 Flash	0,30 / 1,20[3]	**~1,0 s**	**~208–227 tok/s**	**Prioridad alta técnicamente.** Muy buen costo, velocidad y capacidad. Su principal desventaja corresponde a la política y jurisdicción de los datos.
Gemini 3.8 Flash	0,75 / 3,75[4]	~11–16 s	**~239–299 tok/s**	**Prioridad alta.** Mayor capacidad general que las alternativas económicas y velocidad de salida muy elevada. Debe evaluarse con nivel de razonamiento bajo para el requisito de latencia.
Claude Haiku 5.5	**0,10 / 0,50**[5]	Pendiente de estabilización	Pendiente de estabilización	**Prioridad media-alta.** Su precio lo vuelve competitivo con Luna. Al ser un modelo publicado recientemente, las métricas independientes todavía deben considerarse preliminares.
Gemini 3.6 Flash	0,75 / 3,75[4]	~11-17 s	~195 tok/s	**Prioridad media.** Modelo estable y rápido, aunque 3.8 Flash ofrece mayor capacidad por el mismo precio promocional.
GPT-4.1 mini	0,40 / 1,60	**~0,7–0,9 s**	~113–151 tok/s	**Prioridad media.** Modelo sin razonamiento previo, rápido y predecible. Resulta útil como baseline para determinar si el razonamiento adicional de modelos actuales aporta una mejora necesaria.
Gemini 3.5 Flash-Lite	0,30 / 2,50	Variable	Muy alta	**Prioridad media-baja.** Orientado a alto volumen y velocidad, pero con menor capacidad que la línea Flash principal.

Modelo	Costo entrada / salida[1]	TTFT aprox.[2]	Velocidad aprox.[2]	Evaluación preliminar
Gemini 3.1 Flash-Lite	0,25 / 1,50	—	—	**Prioridad baja.** Tiene fecha de retiro anunciada para el 7 de mayo de 2027, por lo que su ciclo de vida coincide de forma poco conveniente con el cronograma del proyecto.
GPT-4o mini	0,15 / 0,60	Baja	Alta	**Prioridad baja.** Continúa siendo económico, pero pertenece a una generación anterior y existen alternativas actuales con mejor relación capacidad/costo.

[1] Valores expresados en USD por millón de tokens de entrada/salida para procesamiento estándar, cuando corresponde.
[2] Las métricas corresponden a varios benchmarks externos y sirven únicamente como referencia preliminar. Pueden variar según configuración, carga y tamaño de la solicitud.
[3] DeepSeek aplica tarifas reducidas en determinados períodos de menor demanda.
[4] Precio promocional vigente hasta el 31 de diciembre de 2026; a partir de 2027 el precio anunciado es de USD 1,50 / 7,50.
[5] Para prompts de hasta 100.000 tokens.

A partir del análisis preliminar se identifican cuatro alternativas especialmente relevantes:

1. **GPT-6 Luna**, como candidato principal por su costo extremadamente bajo, capacidades generales y soporte de salida estructurada.
2. **Gemini 3.8 Flash**, como alternativa de mayor capacidad y elevada velocidad de generación.
3. **Claude Haiku 5.5**, cuyo nuevo esquema de precios lo vuelve comparable económicamente con Luna, aunque requiere más evidencia independiente debido a su reciente lanzamiento.
4. **DeepSeek V4.1 Flash**, como referencia de excelente desempeño técnico y económico, pero condicionado por las consideraciones relacionadas con jurisdicción y tratamiento de datos.

La selección definitiva se realizará mediante un benchmark propio utilizando un conjunto común de casos representativos del sistema. Cada modelo recibirá las mismas instrucciones, contexto y esquema de salida, registrándose:

- Cumplimiento de las restricciones establecidas;
- Validez de la salida estructurada;
- Coherencia y calidad de la propuesta;
- Consistencia entre distintas ejecuciones;
- Calidad de las respuestas en español;
- Tiempo total de generación;

- TTFT y velocidad de generación;
- Cantidad de tokens consumidos;
- Costo por generación.

Aclaraciones respecto del Plan de Proyecto

Esta sección explicita tres diferencias entre el Plan de Proyecto y el catálogo de requerimientos del IA1, indicando su origen y su tratamiento.

Metas cuantitativas de los objetivos específicos

Los objetivos específicos del Plan fijan seis metas medibles. Tres de ellas ya están expresadas en el catálogo del IA1; las otras tres no tienen un requerimiento no funcional asociado.

- Acceso a la información del paciente en menos de 5 segundos → RNF-01
- Usabilidad validada con al menos 3 nutricionistas → RNF-04
- Al menos 2 métricas de seguimiento → RF-21 (variación de peso e IMC y de valores de laboratorio)
- Generación de un plan en menos de 15 segundos → Sin requerimiento asociado
- 95% o más de planes que cumplen las restricciones clínicas → Sin requerimiento asociado
- Reducción de al menos 80% del tiempo de elaboración → Sin requerimiento asociado

Las tres metas sin requerimiento asociado no se incorporaron como requerimientos no funcionales en el IA1 porque dependen de componentes que todavía no existen: el proveedor de IA no está seleccionado, la matriz de reglas clínicas requiere la entrevista de validación con la nutricionista, y la reducción de tiempo necesita una medición de referencia del proceso manual. Fijar umbrales verificables antes de contar con esos elementos habría dado lugar a requerimientos que no podían comprobarse.

Las tres metas se mantienen como objetivos del proyecto. Se propone formalizarlas y medirlas según la tabla 7:

Tabla 7: formalización y medición de las metas pendientes

Meta	**Formalización**	**Medición**
Generación en menos de 15 segundos	Nuevo RNF: tiempo desde la solicitud hasta la propuesta validada disponible en el editor, medido en el percentil 95 sobre un conjunto de casos ficticios.	Preliminar en el Incremento 3; definitiva en el Incremento 4, con el proveedor seleccionado.
95% de cumplimiento de restricciones	Indicador de evaluación sobre el conjunto de casos de prueba clínico-nutricionales del Plan (celiaquía, diabetes, hipertensión, alergias e intolerancias).	Incremento 4, a partir de la trazabilidad de generaciones y hallazgos (RF-41).
Reducción del 80% del tiempo	Protocolo de comparación entre el proceso manual y el asistido con casos equivalentes, según la estrategia del riesgo 17.	Validación final (30/04/2027).

Respecto de la meta del 95%, corresponde precisar su interpretación. Por diseño, el motor determinístico bloquea la aprobación de un plan que contenga una contraindicación registrada (RF-43, RF-46), por lo que ningún plan aprobado debería incumplir una regla cargada; esa propiedad se verifica con pruebas del motor de reglas y no con un porcentaje. La meta del 95% se aplicará, por lo tanto, a las propuestas generadas por la IA antes de la validación: proporción de propuestas que no presentan hallazgos bloqueantes. Este indicador mide la calidad de la generación y permite comparar proveedores, plantillas de prompt y versiones del servicio. Esta formalización se añade al catálogo de requerimientos no funcionales que se describió en el IA1.

Estructura temporal de los planes: diarios y semanales

El alcance del producto del Plan menciona propuestas de planes "diarios, semanales, recetas específicas y planes de viandas personalizadas". El RF-34 del IA1 define una propuesta estructurada **por tipo de comida** (desayuno, almuerzo, merienda y cena) con opciones intercambiables, y excluye expresamente la estructura por días de la semana. Se trata de una **decisión de alcance derivada del relevamiento**, que se fundamenta en lo siguiente:

- **Correspondencia con la práctica relevada.** Los planes alimentarios anonimizados aportados durante el relevamiento organizan el contenido por tipo de comida, con varias opciones para cada una, y no como una grilla de días. El sistema reproduce la estructura del documento que el profesional efectivamente entrega.
- **Coherencia con el método del plato.** Los planes relevados comunican las proporciones mediante la ilustración del método del plato y no mediante cantidades ni calorías (RF-35). Bajo este enfoque, la variedad se logra combinando opciones equivalentes y no prescribiendo un menú fijo para cada día.
- **Flexibilidad para el paciente.** Las opciones intercambiables permiten que el paciente elija según disponibilidad y preferencia, en lugar de seguir una secuencia rígida.
- **Menor superficie de generación y validación.** Una grilla semanal multiplica el contenido (siete días por cuatro comidas) sin aportar información clínica adicional, lo que aumenta el tiempo de generación, la probabilidad de errores de la IA y el volumen a revisar por el profesional.

Los conceptos del Plan quedan cubiertos de la siguiente manera: el plan **diario** corresponde a la estructura por tipo de comida, que describe la alimentación de un día; la cobertura **semanal** se obtiene mediante la variedad de opciones intercambiables; y las **recetas específicas** se cubren con el catálogo de recetas y la generación de recetas (RF-27 a RF-29, RF-38 y RF-39). Si en la entrevista de validación surgiera la necesidad de una vista semanal, se evaluará como cambio de alcance.

Viandas personalizadas

Las viandas forman parte del título y del objetivo general del Plan, y el catálogo del IA1 no incluye un requerimiento que las trate como una salida diferenciada del plan. En el relevamiento, la vianda se identificó como **una comida del plan que el paciente consume fuera del hogar**, habitualmente en su

lugar de trabajo, y no como un producto independiente. Por ese motivo, la vianda quedó **absorbida en la estructura general del plan**:

- **RF-09** registra si el paciente realiza comidas fuera del hogar y con qué medios cuenta para conservarlas o calentarlas.
- **RF-08** y **RF-10** registran el contexto de cocina y los horarios laborales, que condicionan qué preparaciones son viables.
- **RF-27, RF-28 y RF-38** permiten asignar recetas al plan según el tipo de comida, la preferencia y el tiempo de cocina del paciente.
- **RF-34** organiza el plan por tipo de comida; la comida que se consume fuera del hogar es una de ellas, con sus opciones.

En el diseño de la generación asistida, el contexto registrado por RF-08, RF-09 y RF-10 formará parte del contexto anonimizado enviado al servicio de IA, de modo que las opciones de las comidas que se realizan fuera del hogar sean adecuadas para transportarse y conservarse. La personalización de la vianda resulta, entonces, de los mismos datos y validaciones que personalizan el resto del plan, sin un módulo ni un documento separado.

Esta decisión no reduce el objetivo del Plan: las viandas personalizadas siguen siendo parte de lo que el sistema produce, como componente del plan alimentario. El título del proyecto se mantiene.

Conclusiones y próximos pasos

Al finalizar el incremento 1 y siguiendo según el cronograma a partir de la entrega del informe de avance 2 se planifica la implementación del incremento 2 y 3 en lo que respecta al desarrollo de NutrIA y luego la entrega del informe de avance 3. La incorporación de Trello como tablero de gestión de alto nivel va a permitir priorizar las tareas que requieren estos incrementos, no solo a nivel técnico sino también a nivel gestión, incluyendo entrevistas para hacer una demostración de lo realizado con nutricionistas para obtener el feedback necesario para seguir implementando las mejoras que se detallaron en todos los documentos presentados.

Detallando los próximos pasos (no necesariamente en ese orden):

- **Incremento 2 (18/10/2026):** incorporar los datos clínicos y contextuales del paciente (RF-04 a RF-14), las consultas y mediciones, y los catálogos de alimentos, grupos, recetas y recomendaciones, con las migraciones correspondientes del modelo de datos.
- **Entrevistas de validación con la nutricionista:** definir la matriz de reglas clínicas (RF-47) y la composición esperada de desayuno y merienda (punto abierto de RF-26), condición para implementar el motor de reglas en el Incremento 3, y obtener retroalimentación sobre lo realizado.
- **Evaluación de proveedores de IA:** ejecutar el benchmark propio sobre los modelos candidatos de la Tabla 6, con los criterios de la sección "Criterios de selección del proveedor de IA", y registrar la decisión antes del inicio del Incremento 3 (DA-12).
- **Incremento 3 (31/10/2026):** implementar el camino crítico de la generación asistida:

    - Servicio de IA con contrato de entrada y salida, plantilla de prompt versionada y adaptador del proveedor seleccionado.
    - Construcción del contexto mínimo sin datos identificatorios en el backend y resolución de los ítems de la propuesta contra el catálogo de alimentos.
    - Entidades PLAN, PLAN_COMIDA, OPCION, OPCION_ITEM, REGLA_CLINICA, HALLAZGO y GENERACION_IA (Tabla 3).
    - Primera versión del motor determinístico de reglas, con pruebas obligatorias por regla, y advertencias de composición (RF-43, RF-44).
    - Edición de la propuesta por el nutricionista y revalidación ante cada cambio (RF-40, RF-46).
    - Medición preliminar del tiempo de generación e incorporación del requerimiento no funcional correspondiente (meta de 15 segundos, Tabla 7).
- **Definiciones pendientes:** incremento de incorporación del RAG, biblioteca de implementación y composición del corpus (DA-13); plataforma de despliegue (DA-14); y tratamiento de los ítems no reconocidos en el catálogo.